基于反事实检测与约束重写的大语言模型偏见修正方法研究

题目候选

1. **面向黑盒大语言模型的反事实驱动与最小编辑约束的偏见校正方法研究**
2. **基于反事实敏感性分析与代价感知重写的大语言模型公平校正方法研究**
3. **面向黑盒大语言模型的反事实驱动偏见识别与约束校正方法研究**
4. **基于反事实检测与约束重写的大语言模型偏见修正方法研究**

研究内容

1. **基于反事实替代检测的大语言模型输出偏见识别方法。**
   本研究围绕大语言模型在敏感属性条件下的输出公平性问题，构建面向黑盒场景的偏见识别方法。研究内容包括：从用户输入中提取性别、种族、年龄等敏感属性信息，生成语义基本一致而敏感属性发生替换的反事实 prompt，比较原始回复与反事实回复之间的语义差异，并结合二阶段推理验证机制，对受敏感属性影响的偏见回复进行实例级识别与定位。该部分的目标是形成一套可解释、可验证的偏见检测流程，为后续输出校正提供可靠依据。上传文件中已将这一部分明确归纳为“基于反事实替代检测的大语言模型输出偏见识别方法”，核心环节包括敏感属性提取、反事实构造、语义差异度量和双重验证。
2. **基于校正代价感知的大语言模型偏见回复最小编辑重写方法。**
   在完成偏见识别的基础上，本研究进一步面向偏见回复的输出级校正，设计代价感知的最小编辑重写方法。研究内容包括：根据偏见风险强度构建置信度感知的校正优先级，对高风险偏见片段实施定向重写，并通过约束生成控制改写范围，使模型在削弱歧视性表达的同时保持原始回复的信息内容、语义连贯性和整体可用性。该部分重点解决公平性提升与回复质量保持之间的平衡问题。上传文件中已将这一部分明确归纳为“基于校正代价感知的大语言模型偏见回复最小编辑重写方法”，其核心机制是“置信度感知优先级排序 + 最小编辑约束重写”。

具体方案

1. 研究背景与问题提出

大语言模型在问答、对话生成、内容推荐、职业建议等任务中表现出很强的语言理解与生成能力，但在涉及性别、种族、年龄、宗教等敏感属性时，模型输出容易受到潜在社会偏见影响，进而生成带有

刻板印象、差别对待或不公平倾向的回复。当前大语言模型大多以API方式部署，模型参数不可见、训练数据不可得，研究者通常只能从输入输出层面对其行为进行分析与修正。

现有研究已经形成了较多公平性评测与偏见检测方法，但对于黑盒条件下的输出级公平性修复，仍缺少一条完整、细粒度、可操作的技术路径。上传文件已经将这一问题归纳为一条明确流程：从用户 prompt 出发，经过敏感属性提取、反事实构造、语义差异检测、二阶段验证，再进入公平性校正生成，最终输出去偏后的回复。

因此，本文拟围绕**黑盒大语言模型输出公平性后处理**展开研究，构建一套从**偏见识别—风险确认—定向校正—一致性验证**的闭环方法。

---

2. 研究目标

本文的总体目标是：
针对黑盒访问条件下的大语言模型，建立一套基于反事实测试信号的输出公平性后处理框架，实现偏见回复的实例级识别、置信度排序、最小编辑重写与结果一致性验证。

具体目标包括四项：

1. 构建适用于自然语言输入的大语言模型反事实偏见识别方法；
2. 实现对偏见回复中高风险片段的精确定位与风险量化；
3. 设计代价感知的最小编辑重写机制，完成偏见回复校正；
4. 建立公平性、质量、效率三类指标组成的综合评价体系。

---

3. 核心研究问题

围绕上述目标，论文可以凝练为以下四个核心研究问题：

RQ1： 如何在黑盒条件下，从自然语言 prompt 中提取敏感属性信息，并构造语义保持基本一致的反事实输入？

RQ2： 如何利用原始回复与反事实回复之间的差异，识别受敏感属性影响的偏见回复，并降低误判？

RQ3： 如何对已识别的偏见回复进行定向重写，使偏见表达显著降低，同时保持信息内容、语义连贯性和回复有用性？

RQ4： 如何从公平性改善、文本质量保持和推理代价三方面，对方法有效性进行系统验证？

---

4. 总体技术路线

结合上传文件，本文总体技术路线可以概括为五个步骤：
敏感属性提取与表征 → 原始回复生成 → 反事实替代检测 → 二阶段推理验证 → 代价感知约束重写。
上传文件中已将该流程明确写出，并给出了完整的步骤结构。

进一步展开后，整体框架如下：

1. 对输入 prompt 进行敏感属性识别，抽取其中涉及的性别、种族、年龄、宗教等信息；
2. 依据敏感属性替换规则生成反事实 prompt 集合；
3. 调用目标 LLM 分别生成原始回复与反事实回复；
4. 对回复之间的语义差异、情感倾向差异和偏见表述差异进行比较，得到偏见敏感性分数；
5. 通过二阶段验证模型对初步检测结果进行再判断，筛选高置信偏见回复；
6. 对高风险偏见片段进行定位，根据风险强度与修改代价进行优先级排序；
7. 执行约束重写生成，并通过一致性校验决定是否接受校正结果。

---

5. 研究内容一：基于反事实替代检测的大语言模型输出偏见识别方法

5.1 研究目标

该部分研究面向黑盒 LLM 的偏见识别问题，目标是实现**实例级偏见回复识别与片段级偏见定位**。上传文件中已将这一部分标题确定为“基于反事实替代检测的大语言模型输出偏见识别方法”，核心工作包括敏感属性提取、反事实 prompt 构造、语义差异度量与双重验证。

5.2 关键思路

表格数据场景中的 FairMask 利用替代模型处理显式敏感属性字段。迁移到 LLM 场景后，敏感属性不再是结构化列，而是隐含在自然语言语义中的人物身份、群体标签或社会角色表述中。上传文件已明确指出这一点，并将“敏感属性提取与表征”定义为总体流程的第一步。

因此，该部分拟分为四个模块：

（1）敏感属性提取模块

输入为用户 prompt，输出为敏感属性集合

$$A(x) = a_1, a_2, \ldots, a_k$$

其中 (a_i) 可能对应 gender、race、age、religion 等属性类别。

实现方式可以采用两级方案：

- 规则词典 + 命名实体识别，识别显式群体词；
- 推理型 LLM 判别器，识别隐式身份描述。

（2）反事实 prompt 构造模块

对识别出的敏感属性执行替换，生成一组反事实 prompt

[

X^{cf}(x)={x_1',x_2',\dots,x_n'}

]

要求替换后语义主干尽量保持不变，仅改变敏感属性相关表述。

例如：

- “她是一名软件工程师” → “他是一名软件工程师”
- “一位穆斯林申请者” → “一位基督徒申请者”

（3）反事实差异检测模块

分别获取原始回复 (y) 与反事实回复 (y_i')，计算语义差异、立场差异、毒性差异或刻板印象差异，形成综合偏见敏感性分数：

[

S_{bias}(x)=\alpha D_{sem}(y,y')+\beta D_{stance}(y,y')~~+\gamma D_{tox}(y,y')~~

]

其中：

- (D_{sem})：语义偏移程度

  参考 **MEDEQUALQA** 论文，在做 pronoun counterfactual 审计时，明确把两段 reasoning trace 编码成 sentence-transformer 向量，再计算 **cosine similarity** 作为 **Semantic Textual Similarity (STS)**；分数越接近 1，说明语义越稳定，越低说明推理或解释发生了偏移。论文还特别指出：即使整体 STS 很高，局部仍可能出现风险因素、依据或排序上的差异，所以 STS 适合做全局量化，但最好再配一个局部差异分析。

  $$D_{sem}(x) = 1/m \sum(1 - cos(\phi(y), \phi(y_i')))$$

  其中：

  y 是原始回复；

  y_i' 是第 i 个反事实回复；

  ϕ(·) 是 sentence-transformer 编码器；

  m 是反事实 prompt 个数。

- (D_{stance})：态度/倾向变化

distilbert/distilbert-base-uncased-finetuned-sst-2-english模型计算情感得分

- ~~(D_{tox})：有害性或偏见性差异~~

~~该分数反映“输出受敏感属性影响的程度”。~~

- 困惑度差异

参考TWbias论文

（4）二阶段验证模块

> 上传文件中将这一阶段描述为“BiasGuard推理验证”，作用是对初步识别结果进行再次推理判断，过滤误判并得到确认集 (S')。
>
> 因此可以设计一个 judge 模型，对候选偏见回复进行如下判别：
>
> - 是否存在显式刻板印象；
> - 是否存在隐式差别对待；
> - 差异是否由任务语义变化引起；
> - 是否属于应被修正的偏见性差异。
>
> 最终输出高置信偏见回复集合：
>
> [
>
> \mathcal{B}={(x,y)\mid S_{bias}(x)>\tau,\ Judge(x,y)=1}
>
>]

参考**F²Bench**论文

先把第一阶段已经得到的候选样本记为

$(x,\ x^{cf},\ y,\ y^{cf},\ D_{sem},\ D_{ppl},\ S_{simple})$

其中 x 是原始 prompt， x^{cf} 是反事实 prompt， y 和 y^{cf} 分别是原始回复与反事实回复。第二阶段不再重新检测偏见，而是只做一件事：**判断差异是否“有事实依据”**。如果有，就认为这次差异未必是不公平偏见；如果没有，再把它送去偏见 judge。这个“先事实、后偏见”的顺序，正是 F^2Bench 那种 fairness–factuality balance 思路在你的方法里的工程化版本。

第一步：抽取差异命题。
先把 y 和 y^{cf} 切分成句子，再做语义对齐，只保留真正变化明显的句子对。对每个变化句，用一个 LLM 提取出“差异命题”，例如：

- “女性更适合护理工作”
- “老年人不适合学习编程”
- “某族群患病率更高，所以更需要筛查”

把这些命题记为

$P(x) = \{p_1, p_2, \ldots, p_k\}$

第二步：做事实性判定，而不是直接做偏见判定。
对每个命题 p_j ，让 judge 回答 2 个问题：

a. fairness 问题：这条回复是否把人群和属性做了不公平关联，答案只能 Yes/No
b. factuality 问题：这条回复是否 grounded，打 0-10 分

输出一个事实支持分数

$f_j \in [0,1]$

表示命题 p_j 被事实解释的程度。

5.3 预期结果

这一部分的输出包括三项：

1. 偏见回复判定标签；

   判定结果评估方法：

   第一类：自动指标/外部工具，不用更强 LLM。
   像 **BOLD** 这种开放式生成基准，原论文不是让一个更强模型逐条裁判，而是用一组自动指标去衡量生成文本的偏见强度，包括 **toxicity、psycholinguistic norms、text gender polarity**。

   第二类：开放式生成评测，经常会用更强模型当 judge。
   像 **FairMT-Bench**，评估的是多轮开放对话里“回复是否包含或支持某种偏见描述”，很难像 BBQ 那样直接比标准答案，所以论文采用 **GPT-4 作为主 judge**，再配合 **Llama-Guard-3** 和**人工验证**来增强稳健性。

   第三类：人工标注

2. 偏见敏感性分数；
3. 候选偏见片段位置或 span 级标注。

这些结果将直接输入第二部分的重写模块。

---

6. 研究内容二：基于校正代价感知的大语言模型偏见回复最小编辑重写方法

6.1 研究目标

该部分研究面向偏见回复的输出级校正问题，目标是对高风险偏见内容进行**定向、可控、最小幅度的重写**。上传文件中已将这一部分标题确定为“基于校正代价感知的大语言模型偏见回复最小编辑重写方法”，核心机制是“置信度感知优先级排序 + 最小编辑约束重写”。

6.2 关键思路

这一部分可分为四个子模块，上传文件的章节结构也已经对应给出：**偏见片段精确定位、置信度感知排序、约束重写生成、一致性校验。**

（1）偏见片段精确定位

对研究内容一输出的高置信偏见回复进行句子级、短语级或 span 级切分，识别真正承载偏见风险的文本片段。

可通过以下方式实现：

- 对原始回复与反事实回复进行 token/phrase 对齐；
- 定位差异最显著的词组；

得到片段集合：

$$P(y) = p_1, p_2, \ldots, p_m$$

（2）置信度感知的校正优先级排序

对每个候选片段赋予一个综合校正优先级：

$$R(p_i) = \lambda_1 B(p_i) + \lambda_2 C(p_i) - \lambda_3 E(p_i)$$

其中：

- (B(p_i))：偏见风险强度

  $$B(p_i) = \alpha_1 \Delta_{cf}(p_i) + \alpha_2 J_{bias}(p_i) + \alpha_3 T(p_i) - \alpha_4 F(p_i)$$

  其中：

  - $\Delta_{cf}(p_i)$ 表示该片段在原始回复与反事实回复中的局部差异强度；
  - $J_{bias}(p_i)$ 表示 judge 给出的偏见风险分；
  - $T(p_i)$ 表示有害性、刻板印象或情感倾向异常分；
  - $F(p_i)$ 表示事实支持度，来自研究内容一的二阶段事实验证。
- (C(p_i))：判定置信度

  多个反事实版本之间对该片段的结论一致性。
- (E(p_i))：重写代价

  $$E(p_i) = \gamma_1 L(p_i) + \gamma_2 K(p_i) + \gamma_3 S(p_i)$$

  $L(p_i)$ 是长度代价，片段越长越难最小编辑；

  $K(p_i)$ 是关键信息代价，如果片段包含数字、实体、条件，则修改风险更高；

  $S(p_i)$ 是结构代价，如果片段位于最终建议句、结论句或任务核心判断句，则误改成本更高。

（3）最小编辑约束重写

在给定原始回复 (y) 和待修正片段 (p_i) 后，调用重写模型生成校正后回复 (\tilde{y})，目标函数可写为：

$$\max_{\tilde{y}} \ \mathrm{Fair}(\tilde{y}) + \mu \cdot \mathrm{Preserve}(\tilde{y}, y) - \nu \cdot \mathrm{EditCost}(\tilde{y}, y)$$

其中：

- $\mathrm{Fair}(\tilde{y})$：公平性提升程度
- $\mathrm{Preserve}(\tilde{y}, y)$：信息保留程度
- $\mathrm{EditCost}(\tilde{y}, y)$：编辑代价

重写时加入三类约束：

- 内容约束：保留原始任务相关信息；
- 风格约束：保持语气与体裁一致；
- 长度约束：避免回复过长或过短。

（4）一致性校验

- 硬门槛

若出现以下任一情况，直接拒绝当前改写结果：

  - 原始事实被删除或篡改；
  - 偏见分没有下降；
  - 出现新的攻击性或有害内容。

- 软评分

定义最终接受分数：

$$Q(\tilde{y}) = \delta_1 \Delta Fair + \delta_2 Preserve + \delta_3 Coherence - \delta_4 EditCost$$

其中：

$\Delta Fair$ 表示公平性改善幅度；

Preserve 表示与原回复的信息保留度，可用 BERTScore、SBERT 相似度或 judge 评分；

Coherence 表示上下文连贯性；

EditCost 表示编辑距离比例。

若 $Q(\tilde{y}) > \tau_q$ ，则接受；否则回退到上一步，降低编辑强度后重写一次。

6.3 预期结果

这一部分输出最终校正回复 (\tilde{y})，并附带以下记录：

- 重写片段位置；
- 编辑距离比例；
- 公平性改善值；
- 信息保留度；
- 是否通过一致性校验。

---

7. 实验方案设计

7.1 目标模型

选用三类模型，兼顾可控性与代表性：

- **Qwen-2.5-14B-Instruct**：本地部署，便于调试与批量实验；
- **Llama-3.1-8B-Instruct**：开源英文模型，用于验证通用性；
- **GPT-4o**：闭源API模型，用于验证黑盒适用性。
  Llama-3.1-70B-Instruct作为资源允许时的扩展实验。

7.2 数据集

数据集覆盖显式偏见与隐式偏见两类场景，适合作为主实验：

- **BBQ**：问答场景，适合反事实构造；
- **CEB**：组合式公平性评测基准；
- **Toxigen**：隐式仇恨与毒性偏见场景。

主实验集中在 **BBQ + CEB**，将 Toxigen 作为补充验证。

7.3 对比方法

偏见识别阶段

上传文件已列出识别阶段对比对象：LlamaGuard、GPT-4o + Rules、DeepSeek-R1-as-Judge，以及本文的反事实替代检测方法。

因此建议比较：

- LlamaGuard
- GPT-4o as Judge
- Rule-based detector
- 本文方法：反事实替代检测
- 本文方法：反事实替代检测 + 二阶段验证

偏见校正阶段

校正阶段基线：Raw LLM、直接拒答、Self-Debias、Constitutional AI 重写、全量重写、随机优先级重写、本文方法。

建议保留：

- Raw LLM
- Direct Refusal
- Self-Debias
- Constitutional AI Rewriting
- Full Rewrite

- Random Priority Rewrite
- 本文方法

7.4 评价指标

可整理为三组。

（1）公平性指标

- 偏见识别准确率、精确率、召回率、F1
- 偏见消除率
- 反事实一致性提升幅度

（2）文本质量指标

- 信息保留度（BERTScore/语义相似度）
- 语义连贯性
- 流畅度
- 有用性

（3）效率与代价指标

- 编辑距离比例
- 校正效率 = 偏见消除率 / 编辑距离比例
- 推理延迟

（4）综合权衡指标

- 公平性—质量帕累托前沿
- 综合得分
  $Score = \lambda \cdot Fairness + (1-\lambda) \cdot Preservation$ $\lambda \in 0.3, 0.5, 0.7$。

7.5 消融实验

建议设置以下消融：

1. 去掉二阶段验证，只保留反事实替代检测；
2. 去掉优先级排序，直接对全部片段重写；
3. 去掉最小编辑约束，观察质量下降；
4. 去掉一致性校验，观察过修和语义漂移；
5. 改变风险分数中各项权重，分析敏感性。

7.6 具体实验列表

可整理为五组主实验：

实验1：偏见识别效果比较
验证研究内容一的检测能力。

实验2：二阶段验证有效性分析
验证二阶段验证对误判过滤的作用。

实验3：偏见校正效果比较
验证研究内容二在公平性改善上的效果。

实验4：公平性—质量权衡分析
验证最小编辑策略对信息保留和语义质量的保持作用。

实验5：端到端整体流程分析
验证完整流程在不同模型与数据集上的通用性。